

## Проверка статистических гипотез

**ГИПОТЕЗА** — любое суждение о неизвестном распределении

**ПРОСТАЯ** гипотеза однозначно восстанавливает распределение

**СЛОЖНАЯ** гипотеза неоднозначно восстанавливает распределение

Пример  $H_1 = \{X \in N(0,1)\}$  — простая гипотеза

$H_2 = \{X \in N(\alpha, \delta)\}$  — сложная гипотеза

**СТАТИСТИЧЕСКОЕ РЕШАЮЩЕЕ ПРАВИЛО (КРИТЕРИЙ)** —

m-точечное отображение выборочного пространства

Обозн  $\delta(X) = \begin{cases} 1, & \text{если } \dots \\ : & \dots \\ m, & \text{если } \dots \end{cases}$   $1, \dots, m$  — индексы гипотез  $H_1, \dots, H_m$

$\alpha_i(\delta) = P_i(\delta \neq i)$  — **ВЕРОЯТНОСТЬ ОШИБКИ i-ГО РОДА**

Пример У врача  $H_1 = \{\text{здоров}\}$  Ошибка I рода — лежат здорового  
 $H_2 = \{\text{болен}\}$  Ошибка II рода — не лежат больного

ЛУЧШЕ тот критерий, у которого вероятности ошибок меньше  
 сделать очень маленьких. Вероятности ошибок всех родов одновременно невозм.

**Метод минимального расстояния**

$H_1 = \{F = F_0\}$  — **ОСНОВНАЯ** гипотеза

$H_2 = \{F \neq F_0\}$  — **АЛЬТЕРНАТИВНАЯ** гипотеза (**АЛЬТЕРНАТИВА**)

В рассматриваемой паре гипотез основная — простая, альтернативная — сложная

$d(F_1, F_2)$  — **СТАТИСТИЧЕСКОЕ РАССТОЯНИЕ**, если ①  $d(F_1, F_2) \geq 0$   
 это не метрика! нет нерва треуг.  
 и точности

Замечание  $F_n^*(t) = \frac{\#\{X_i | X_i < t\}}{n}$

$\sup_t |F_n^*(t) - F_0(t)| \xrightarrow{n \rightarrow \infty} 0$  по т. Глив-Кантори  
 ↴ расстояние Калаборова  $d_K(F_n^*, F_0)$

Статистическое расстояние напр. отн.  $d_K \Rightarrow$   
 $\Rightarrow d(F_n^*, F_0) \xrightarrow{n \rightarrow \infty} 0$

Вернемся к  $H_1 = \{F = F_0\}$ ,  $H_2 = \{F \neq F_0\}$

Метод мин. расст. :  $\delta(X) = \begin{cases} 1, & d(F_n^*, F_0) \leq c_\varepsilon \\ 2, & d(F_n^*, F_0) > c_\varepsilon \end{cases}$  критическое значение

$$\varepsilon = \alpha_1(\delta) = P_1(\delta=2) = \frac{P_1(d(F_n^*, F_0) > c_\varepsilon)}{\text{отсюда имеем } c_\varepsilon}$$

По сути - квантиль уровня  $\varepsilon$

### Критерий Колмогорова

$$d_K(F_1, F_2) = \sup_t |F_1(t) - F_2(t)|$$

Лемма (Свойство непараметричности критерия Колмогорова)

$F_0$  (истинное расп) — непрерывная ф-я

$\Rightarrow P(d_K(F_n^*, F_0) < t)$  не зависит от  $F_0$  (параметром как раз считается  $F_0$ )

Д-бо



$$\sup_t |F_n^*(t) - F_0(t)| = \sup_{0 \leq s \leq 1} |F_n^*(F_0^{-1}(s)) - F_0(F_0^{-1}(s))|$$

квантильное преобраз.

$$= \sup_{0 \leq s \leq 1} |F_n^*(F_0^{-1}(s)) - s| = |F_n^*(t) = \frac{1}{n} \sum_{i=1}^n I\{X_i < t\}| =$$

$$= \sup_{0 \leq s \leq 1} \left| \frac{1}{n} \sum_{i=1}^n I(F_0(x_i) < s) - s \right|$$

имеет равномерное на  $[0, 1]$  распределение

T.o.  $P(d_K(F_n^*, F_0) < t) = P(d_K(U_n^*, U_{0,1}) < t)$  — не зависит от  $F_0$  ■

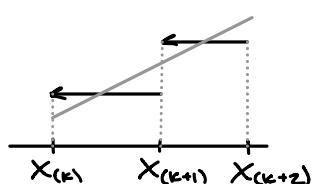
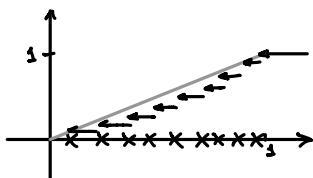
### Теорема Колмогорова

$$P(\sqrt{n} d_K(F_n^*, F_0) < t) \xrightarrow{n \rightarrow \infty} K(t) := \sum_{k=-\infty}^{+\infty} (-s)^k e^{-2k^2 t^2}$$

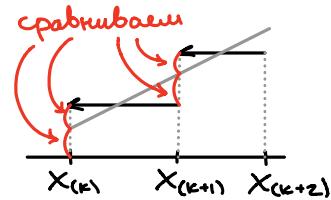
функция Колмогорова

Как считать расчетное задание

если приблизить:



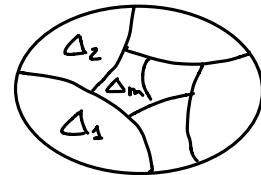
$\sup |F_n^* - F_0|$   
достигается в  
узлах



## Расстояние $\chi^2$

Делаем когерентное разбиение  $X$

$$\{\Delta_1, \dots, \Delta_m\} \quad \gamma_i = n P_n^*(\Delta_i)$$



$$P_1(\Delta) = P_1(X_i \in \Delta) \quad X_i \in X$$

$$P_2(\Delta) = P_2(X_i \in \Delta)$$

$$d_{\chi^2}(P_1, P_2) = \sum_{i=1}^m \frac{(P_1(\Delta_i) - P_2(\Delta_i))^2}{P_2(\Delta_i)} \quad - \text{РАСТОЯНИЕ } \chi^2$$

$$d(P_n^*, P_0) = \sum_{i=1}^m \frac{(\gamma_i - p_i)^2}{p_i} = \sum_{i=1}^n \frac{(\gamma_i - np_i)^2}{n^2 p} \quad \xrightarrow{\text{истинное расп}}$$

### Теорема Пирсона

$$nd_{\chi^2}(P_n^*, P_0) \Rightarrow \eta \in \chi^2_{m-1} \iff \eta \stackrel{d}{=} \sum_{i=1}^{m-1} \xi_i^2, \quad \xi \sim N_{0,1}$$

### Теорема Пирсона (обобщенная)

$H_0 = \{X \in \{F_0\}\}$  — основная гипотеза сложная  
 $H_1 = F_0$

$$\Rightarrow nd_{\chi^2}(P_n^*, P_0) \Rightarrow \eta \in \chi^2_{m-1 - \dim(\Theta)}$$

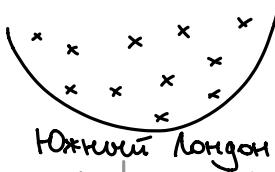
$\xrightarrow{\text{А-Бо}}$   $d(P_n^*, P_0) = \sum \frac{(\gamma_i - np_i)^2}{n^2 p_i}$ , где  $p_i = p_i(\theta)$

вместо  $\theta$  возьмем ОМП  $\hat{\theta}_n$

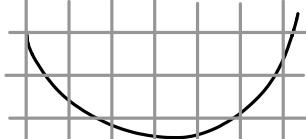
Пример  $X \in \{N(\alpha, \delta) \mid \alpha \in \mathbb{R}, \delta > 0\}$   $\theta = (\alpha, \delta) \leftarrow (\bar{x}, s)$

Замечание При небольших объемах выборки разбиваем так, что  $n p_i \approx \gamma_i$  и  $\gamma_i \geq 10$

Пример Лондон, II Мировая Война



$H_0 = \{\text{ракеты попадают на целевую точку}\}$   
 $H_1 = \{\text{ракеты попадают в квадрат}\}$



576 квадратов

$i$ -количество попаданий в квадрат  
 $\gamma_i$  — количество таких квадратов

i	0	1	2	3	4+
7	229	211	93	35	8

$P = \frac{1}{576}$  - вероятность попадания ракеты в отдельный квадрат, если то верна

По сути проверим Пуассоновость распределения ( $np = \lambda$ )

$$d_{\chi^2}(P^*, P_0) \approx 2,5$$

↳  $\Pi_{np}$

$$np = \frac{535}{576} \approx 0,9$$